

* Exploratory Data Analysis (EDA)

Dataset Aspect-Based Sentiment Analysis (ABSA)

Sumber: Review Google Places

Deskripsi

Notebook ini bertujuan untuk menganalisis karakteristik dataset hasil anotasi ABSA dengan aspek:

- Product
- Price
- Place
- Promotion

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import re
import json
from sklearn.preprocessing import MultiLabelBinarizer

sns.set(style="whitegrid")

data = []
error_lines = []

file_path = "Kelp2_dataset_anotasi.jsonl"

with open(file_path, 'r', encoding='utf-8') as f:
    for i, line in enumerate(f):
        try:
            data.append(json.loads(line))
        except Exception as e:
            error_lines.append((i+1, str(e)))

df = pd.DataFrame(data)

print("\nJumlah data berhasil:", len(df))
print("Jumlah error:", len(error_lines))

df.info()

def clean_text(text):
```

```

    text = str(text).lower()
    text = re.sub(r'^a-zA-Z\s', '', text)
    text = re.sub(r'\s+', ' ', text).strip()
    return text

if 'clean_text' in df.columns:
    df['clean_text'] = df['clean_text'].apply(clean_text)
elif 'text' in df.columns:
    df['clean_text'] = df['text'].apply(clean_text)

```

```

Jumlah data berhasil: 678
Jumlah error: 1
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 678 entries, 0 to 677
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
----  -----
0   text                   678 non-null    object
1   tokens                 678 non-null    object
2   spans                  678 non-null    object
3   _input_hash            678 non-null    int64
4   _task_hash             678 non-null    int64
5   options                678 non-null    object
6   _view_id               678 non-null    object
7   config                 678 non-null    object
8   accept                 678 non-null    object
9   answer                 678 non-null    object
10  _timestamp             678 non-null    int64
11  _annotator_id          678 non-null    object
12  _session_id            678 non-null    object
13  flagged                 1 non-null      object
dtypes: int64(3), object(11)
memory usage: 74.3+ KB

```

Dataset yang digunakan dalam analisis ini merupakan hasil proses cleaning dari data anotasi awal. Setelah proses pembersihan data, jumlah data yang dapat digunakan sebanyak 678 review.

Jumlah ini berada di bawah ketentuan minimum proyek (800 data), namun tetap digunakan untuk menjaga kualitas data yang dianalisis, dengan menghindari data yang tidak valid atau rusak.

```

df['label'] = df['accept'].apply(lambda x: x if isinstance(x, list) else []) if
df['spans'] = df['spans'].apply(lambda x: x if isinstance(x, list) else []) if

df['word_count'] = df['clean_text'].apply(lambda x: len(str(x).split()))

print("Kolom yang tersedia:", df.columns.tolist())
print("Jumlah baris:", len(df))

```

Kolom yang tersedia: ['text', 'tokens', 'spans', '_input_hash', '_task_hash', 'o
Jumlah baris: 678

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

sns.set(style="whitegrid")

if 'accept' not in df.columns:
    raise ValueError("Kolom 'accept' tidak ditemukan di dataframe")

label_counts = (
    df['accept']
    .dropna()
    .explode()
    .value_counts()
    .reset_index()
)

label_counts.columns = ['label', 'count']

label_counts = label_counts.sort_values(by='count', ascending=False)


print(label_counts.head())

plt.figure(figsize=(12, 5))
sns.barplot(data=label_counts, x='label', y='count')

plt.xticks(rotation=45, ha='right')
plt.title("Distribusi Label ABSA")
plt.xlabel("Label")
plt.ylabel("Jumlah")

plt.tight_layout()
plt.show()
```

	label	count
0	PRODUCT_POSITIVE	526
1	PLACE_POSITIVE	229
2	PRICE_POSITIVE	111
3	PRODUCT_NEGATIVE	38
4	OUT_OF_TOPIC	38



Berdasarkan distribusi label ABSA, terlihat bahwa label yang paling dominan adalah PRODUCT_POSITIVE dengan jumlah 526, diikuti oleh PLACE_POSITIVE dan PRICE_POSITIVE. Hal ini menunjukkan bahwa mayoritas ulasan cenderung memberikan sentimen positif, khususnya terhadap aspek produk.

Sebaliknya, label negatif seperti PRODUCT_NEGATIVE memiliki jumlah yang jauh lebih sedikit, dan beberapa label seperti OUT_OF_TOPIC juga memiliki frekuensi rendah. Hal ini menunjukkan adanya ketidakseimbangan distribusi label dalam dataset.

Dominasi label positif ini mengindikasikan bahwa pengguna lebih sering memberikan ulasan positif dibandingkan negatif, yang berpotensi menyebabkan bias pada model dalam memprediksi sentimen.

```

entities = []

for spans in df['spans']:
    if isinstance(spans, list):
        for s in spans:
            if isinstance(s, dict) and 'label' in s:
                entities.append(s['label'])

entity_counts = pd.Series(entities).value_counts().reset_index()
entity_counts.columns = ['entity', 'count']

```

```

entity_counts = entity_counts.sort_values(by='count', ascending=False)

print(entity_counts.head())


plt.figure(figsize=(10, 5))
sns.barplot(data=entity_counts, x='entity', y='count')

plt.xticks(rotation=45, ha='right')
plt.title("Distribusi Entitas NER (Spans)")
plt.xlabel("Entitas")
plt.ylabel("Jumlah")

plt.tight_layout()
plt.show()

```

	entity	count
0	PRODUCT_POSITIVE	717
1	PLACE_POSITIVE	289
2	PRICE_POSITIVE	108
3	OUT_OF_TOPIC	41
4	PROMOTION_POSITIVE	33




Berdasarkan distribusi entitas, terlihat bahwa entitas yang paling dominan adalah PRODUCT_POSITIVE dengan jumlah 717, diikuti oleh PLACE_POSITIVE sebanyak 289 dan PRICE_POSITIVE sebanyak 108. Hal ini menunjukkan bahwa sebagian besar anotasi dalam dataset berfokus pada aspek produk, diikuti oleh pengalaman di tempat dan harga.

Selain itu, entitas seperti OUT_OF_TOPIC dan PROMOTION_POSITIVE memiliki jumlah yang relatif kecil dibandingkan kategori utama. Hal ini menunjukkan adanya ketidakseimbangan distribusi entitas, di mana beberapa kategori memiliki jumlah data yang jauh lebih sedikit.


Dominasi entitas PRODUCT_POSITIVE mengindikasikan bahwa pengguna lebih sering menyoroti kualitas produk secara positif dalam ulasan mereka. Kondisi ini dapat mempengaruhi performa model, khususnya dalam mengenali entitas yang jarang muncul.

```
plt.figure(figsize=(8, 5))
sns.histplot(df['word_count'], bins=30, kde=True)
plt.title("Distribusi Panjang Review (kata)")
plt.xlabel("Jumlah Kata")
plt.ylabel("Frekuensi")
plt.tight_layout()
plt.show()
```



```
mlb = MultiLabelBinarizer()
label_matrix = mlb.fit_transform(df['label'])
label_df = pd.DataFrame(label_matrix, columns=mlb.classes_)
```

```
plt.figure(figsize=(12, 9))
sns.heatmap(label_df.corr(), cmap="coolwarm", linewidths=0.5)
plt.title("Korelasi Antar Label")
plt.tight_layout()
plt.show()
```



```
print("\n=== Statistik Dataset ===")
print("Jumlah data      :", len(df))
print("Rata-rata panjang :", round(df['word_count'].mean(), 2))
print("Review terpanjang :", df['word_count'].max())
print("Review terpendek  :", df['word_count'].min())
```

```
=== Statistik Dataset ===
Jumlah data      : 678
Rata-rata panjang : 13.72
Review terpanjang : 261
Review terpendek  : 1
```

```
print("\nSample data:")
print(df[['text', 'label']].sample(5))
```

Sample data:

	text	label
493	kualitas produk sejauh ini konsisten bahan bagus	[PRODUCT_POSITIVE]
548	bahannya bagus jaitannya juga tapi jaitan kanc...	[PRODUCT_POSITIVE, PRODUCT_NEGATIVE]
7	gak bisa qris di bawah 50rb padahal mau bayari...	[PLACE_NEGATIVE]
278	rekomendasi banget tempatnya nyaman	[PLACE_POSITIVE]
596	bahan premium model jelas kece rekom sii	[PRODUCT_POSITIVE]

* Inter-Annotator Agreement (IRR)

Bagian ini bertujuan untuk mengevaluasi tingkat kesepakatan antar annotator dalam proses anotasi dataset menggunakan beberapa metrik seperti Krippendorff Alpha, Percent Agreement, dan Gwet AC2.

```
import json
import pandas as pd

with open("nlp2_iaaa_textcat.jsonl", "r") as f:
    textcat_irr = json.load(f)

df_irr = pd.DataFrame(textcat_irr).T

df_irr_summary = df_irr[["kripp_alpha", "percent_agreement", "gwet_ac2"]].copy()

def interpret_alpha(alpha):
    if pd.isna(alpha):
        return "Tidak ada data"
    elif alpha >= 0.8:
        return "Sangat Baik"
    elif alpha >= 0.6:
        return "Baik"
    elif alpha >= 0.4:
        return "Cukup"
    elif alpha >= 0.2:
        return "Rendah"
    else:
        return "Sangat Rendah"
```



```
df_irr_summary["kategori"] = df_irr_summary["kripp_alpha"].apply(interpret_alpha)
df_irr_summary = df_irr_summary.sort_values(by="kripp_alpha", ascending=False)
df_irr_summary
```

	kripp_alpha	percent_agreement	gwet_ac2	kategori
PRICE_POSITIVE	0.904965	0.971491	0.958979	Sangat Baik
PLACE_POSITIVE	0.767055	0.892544	0.800461	Baik
PLACE_NEGATIVE	0.740130	0.980576	0.978984	Baik
PRODUCT_POSITIVE	0.721596	0.896930	0.835494	Baik
PRODUCT_NEGATIVE	0.704467	0.954887	0.946897	Baik
PROMOTION_POSITIVE	0.613412	0.984962	0.984310	Baik
OUT_OF_TOPIC	0.515148	0.960213	0.956487	Cukup
PRICE_NEGATIVE	0.286245	0.987469	0.987258	Rendah
PRODUCT_NEUTRAL	0.230657	0.970551	0.969405	Rendah
PRICE_NEUTRAL	0.153289	0.985902	0.985644	Sangat Rendah
PROMOTION_NEUTRAL	0.108756	0.994674	0.994643	Sangat Rendah
PLACE_NEUTRAL	0.108756	0.994987	0.994950	Sangat Rendah


Berdasarkan hasil Inter-Annotator Agreement (IRR), terlihat bahwa label dengan sentimen positif memiliki tingkat kesepakatan yang relatif tinggi. Hal ini ditunjukkan oleh nilai Krippendorff's Alpha yang berada pada kategori baik hingga sangat baik, seperti pada PRICE_POSITIVE (0.90) dan beberapa label positif lainnya.

Sebaliknya, label dengan sentimen netral dan beberapa kategori negatif menunjukkan nilai alpha yang rendah hingga sangat rendah. Bahkan terdapat label seperti PROMOTION_NEGATIVE yang memiliki nilai mendekati nol, yang mengindikasikan hampir tidak adanya kesepakatan antar anotator.

Pola ini menunjukkan bahwa anotator cenderung lebih konsisten dalam mengidentifikasi sentimen positif dibandingkan netral atau negatif. Hal ini kemungkinan disebabkan oleh ambiguitas dalam definisi label netral atau kesulitan dalam membedakan konteks tertentu, terutama pada kategori promosi.

Kondisi ini mengindikasikan adanya ketidakseimbangan kualitas anotasi antar label, yang berpotensi mempengaruhi performa model dalam mengenali kategori dengan tingkat kesepakatan rendah.

```
df_irr_summary["kripp_alpha"].sort_values().plot(kind="barh")  
plt.title("Krippendorff Alpha per Label")  
plt.xlabel("Alpha")  
plt.show()
```



Rendahnya nilai agreement pada beberapa label disebabkan oleh beberapa faktor. Pertama, terdapat ketidakseimbangan distribusi data, di mana beberapa label seperti PROMOTION dan kategori NEUTRAL memiliki jumlah data yang sangat sedikit sehingga menyebabkan nilai agreement menjadi tidak stabil.

Kedua, label seperti "neutral" bersifat ambigu dan sangat bergantung pada interpretasi subjektif annotator, sehingga meningkatkan kemungkinan perbedaan penilaian.

Selain itu, meskipun nilai percent agreement terlihat tinggi, hal ini tidak selalu mencerminkan kesepakatan yang sebenarnya karena sebagian besar data tidak mengandung label tertentu.

```
with open("nlp2_iaaa.jsonl") as f:
    iaaa = json.load(f)

print("Pairwise F1:", iaaa["pairwise_f1"])
print("Pairwise Precision:", iaaa["pairwise_precision"])
print("Pairwise Recall:", iaaa["pairwise_recall"])

Pairwise F1: 0.26
Pairwise Precision: 0.26
Pairwise Recall: 0.28
```

Berdasarkan metrik pairwise F1, precision, dan recall, nilai yang relatif rendah menunjukkan bahwa tingkat kesepakatan antar annotator dalam memberikan label masih belum optimal.

Hal ini memperkuat temuan sebelumnya bahwa terdapat ketidakkonsistenan dalam proses anotasi, terutama pada label dengan distribusi data yang tidak seimbang dan definisi yang ambigu.

Secara keseluruhan, kualitas anotasi dataset berada pada tingkat menengah. Beberapa label utama menunjukkan konsistensi yang baik, namun masih terdapat label dengan

```

import streamlit as st
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import json
import re
from sklearn.preprocessing import MultiLabelBinarizer

sns.set(style="whitegrid")

theme = st.sidebar.radio("🎨 Theme", ["Light", "Dark"])

if theme == "Dark":
    st.markdown("""
        <style>
        .stApp {
            background: linear-gradient(135deg, #0f2027, #203a43, #2c5364);
            color: white;
        }
        </style>
        """, unsafe_allow_html=True)
else:
    st.markdown("""
        <style>
        .stApp {
            background: linear-gradient(135deg, #f5f7fa, #c3cfe2);
        }
        </style>
        """, unsafe_allow_html=True)

st.title("📊 Dashboard EDA & IRR - ABSA")

uploaded_file = st.file_uploader("Upload file JSONL", type=["jsonl"])

if uploaded_file:
    data = []
    errors = 0

    lines = uploaded_file.read().decode("utf-8").splitlines()

    for line in lines:
        try:
            data.append(json.loads(line))
        except:
            errors += 1

    df = pd.DataFrame(data)

    st.success(f"Data: {len(df)} baris | Error: {errors}")

    def clean_text(text):
        text = str(text).lower()
        text = re.sub(r'^a-zA-Z\s', '', text)
        text = re.sub(r'\s+', ' ', text).strip()
        return text

    df['clean_text'] = df['text'].apply(clean_text)

    st.subheader("📋 Dataset Preview")
    with st.expander("Lihat Dataset"):
        st.dataframe(df[['text', 'accept']].head(50), use_container_width=True)

    menu = st.sidebar.selectbox(
        "Pilih Analisis",
        ["Distribusi Label", "Distribusi Entitas", "Panjang Review", "Korelasi Label", "NER Viewer"]
    )

    if menu == "Distribusi Label":
        st.subheader("📊 Distribusi Label ABSA")

        labels = df['accept'].dropna().explode()
        label_counts = labels.value_counts().sort_values(ascending=False)

        fig, ax = plt.subplots()

```

```
sns.barplot(x=label_counts.index, y=label_counts.values, ax=ax)
```

```

ax.set_xlabel("Label")
ax.set_ylabel("Jumlah")
plt.xticks(rotation=30, ha='right')

st.pyplot(fig)

st.markdown("""
**Insight:**

Dataset yang digunakan merupakan hasil cleaning sehingga tersisa **678 review**.
Jumlah ini di bawah standar 800 data, namun dipertahankan untuk menjaga kualitas.

- Label dominan: **PRODUCT_POSITIVE**
- Diikuti: **PLACE_POSITIVE**, **PRICE_POSITIVE**
- Label negatif sangat sedikit

➤ Dataset **tidak seimbang (class imbalance)**
➤ Model berpotensi bias ke sentimen positif
""")

elif menu == "Distribusi Entitas":
    st.subheader("📊 Distribusi Entitas")

    entities = []
    for spans in df['spans']:
        if isinstance(spans, list):
            for s in spans:
                if 'label' in s:
                    entities.append(s['label'])

    entity_counts = pd.Series(entities).value_counts()

    fig, ax = plt.subplots()
    sns.barplot(x=entity_counts.index, y=entity_counts.values, ax=ax)

    plt.xticks(rotation=30, ha='right')
    st.pyplot(fig)

    st.markdown("""
**Insight:**

- Dominasi: **PRODUCT_POSITIVE**
- Diikuti: **PLACE_POSITIVE**, **PRICE_POSITIVE**
- Entitas lain jauh lebih sedikit

➤ Distribusi tidak merata
➤ Model sulit belajar entitas minor
""")

elif menu == "Panjang Review":
    st.subheader("📊 Distribusi Panjang Review")

    df['length'] = df['clean_text'].apply(lambda x: len(x.split()))

    fig, ax = plt.subplots()
    sns.histplot(df['length'], bins=30, kde=True, ax=ax)

    st.pyplot(fig)

    st.markdown("""
**Insight:**

- Mayoritas review pendek-sedang
- Sedikit yang sangat panjang

➤ Cocok untuk model NLP umum
""")

elif menu == "Korelasi Label":
    st.subheader("📊 Korelasi Antar Label")

    mlb = MultiLabelBinarizer()
    label_matrix = mlb.fit_transform(df['accept'])

    df_label = pd.DataFrame(label_matrix, columns=mlb.classes_)
    corr = df_label.corr()

```

```

fig, ax = plt.subplots(figsize=(10, 6))
sns.heatmap(corr, annot=True, cmap='coolwarm', ax=ax)

st.pyplot(fig)

elif menu == "NER Viewer":
    st.subheader("🔍 NER Viewer (Slide Data)")

    idx = st.slider("Pilih Index Data", 0, len(df)-1, 0)

    text = df.iloc[idx]['text']
    spans = df.iloc[idx]['spans']

    st.write("### 📄 Text")
    st.write(text)

    st.write("### 🏷️ Entity Highlight")

    # COLOR MAP
    color_map = {
        "PRODUCT": "#1f77b4",
        "PRICE": "#2ca02c",
        "PLACE": "#ff7f0e",
        "PROMOTION": "#9467bd",
        "POSITIVE": "#2ecc71",
        "NEGATIVE": "#e74c3c",
        "NEUTRAL": "#7f8c8d"
    }

    def get_color(label):
        for key in color_map:
            if key in label:
                return color_map[key]
        return "#95a5a6"

    colored_text = text

    if isinstance(spans, list):
        for span in spans[::-1]:
            start = span['start']
            end = span['end']
            label = span['label']
            color = get_color(label)

            colored_text = (
                colored_text[:start] +
                f"<span style='background-color:{color};color:white;padding:4px 8px;border-radius:6px'>"
                f"{text[start:end]} ({label})</span>" +
                colored_text[end:]
            )

    st.markdown(colored_text, unsafe_allow_html=True)

    # LEGEND
    st.write("### 📖 Legend")
    legend_html = ""
    for key, val in color_map.items():
        legend_html += f"<span style='background-color:{val};color:white;padding:6px 12px;margin:5px;border-radius:6px'>{key}"

    st.markdown(legend_html, unsafe_allow_html=True)

st.header("🤝 Inter-Annotator Agreement (IRR)")

irr_file = st.file_uploader("Upload IRR JSONL", type=["jsonl"])

if irr_file:
    irr_data = json.load(irr_file)

    df_irr = pd.DataFrame(irr_data).T
    df_irr_summary = df_irr[["kripp_alpha", "percent_agreement", "gwet_ac2"]]

    st.dataframe(df_irr_summary)

    st.markdown("""
    **Insight IRR:**

    - Label positif → agreement tinggi

```

- Label netral & negatif → rendah
 - Ada inkonsistensi anotasi
- Perlu perbaikan guideline anotasi """)